



Framework Integrado de Conformidade para Dispositivos Médicos com Inteligência Artificial

Grupo 6

João Figueiredo José Mota Leonardo Luís

Mafalda França Martim Pinheiro Rodrigo Lopes

Junho de 2026



PECI - Grupo 6

Orientação: Filipe Sousa, Eduardo Barbosa, Inês Lopes

Conteúdo

1	Introdução	6
1.1	Contextualização do Problema	6
1.2	A Solução: BridgeMedAI	6
2	Estado da arte, ferramentas e tecnologias	8
2.1	Estado da arte	8
2.2	Ferramentas e Tecnologias	8
2.3	RAG e mitigação de alucinações	8
3	Levantamento de requisitos e arquitetura	9
3.1	Levantamento de Requisitos	9
3.2	Arquitetura do Sistema	10
4	Implementação Técnica	11
4.1	Arquitetura em Camadas	11
4.2	Serviços Principais do Backend	11
4.3	Persistência de Dados	12
4.4	Integração com LLM e Embeddings	12
4.5	Autenticação e Autorização	12
4.6	Fluxo de Processamento Completo	13
4.7	Escalabilidade e Modularidade	13
5	Análise Pormenorizada de Requisitos	14
5.1	Enquadramento dos Requisitos Regulatórios	14
5.2	Estrutura de Mapeamento de Requisitos	15
5.3	Exemplo Concreto de Mapeamento: Requisitos para Dispositivo com IA	16
5.4	Matriz de Rastreabilidade (Traceability Matrix – RTM)	17
5.5	Dependências de Documentos e Fluxo Regulatório	17
5.6	Campos Auto-Preenchidos vs. Expertise Humana Obrigatória	17

5.7	Integração de GDPR e Cybersecurity	18
6	Fluxos de Utilizador	19
6.1	Definição de Papéis e Permissões	19
6.2	Fluxo do Customer (Utilizador Cliente)	19
6.3	Fluxo do Specialist (Utilizador Especialista Regulatório)	20
6.4	Fluxo do Admin (Administrador do Sistema)	21
6.5	Ciclo de Vida Completo de Uma Submissão	22
6.6	Rastreabilidade e Auditoria	23
7	Detalhes da Integração de Retrieval-Augmented Generation (RAG)	24
7.1	Visão Geral da Pipeline RAG	24
7.2	Ingestão e Indexação de Documentação Regulatória	24
7.3	Análise da Intenção e Detecção do Perfil	25
7.4	Construção de Variantes de Query e Retrieval Semântico	25
7.5	Ranking e Ajuste de Scores com Heurísticas do Domínio	26
7.6	Construção de Contexto Estruturado	26
7.7	Construção de Prompt Estruturado e Adaptação por Intenção	26
7.8	Geração de Resposta com Ollama e Mitigação de Alucinações	26
7.9	Rastreabilidade e Auditoria da Pipeline RAG	27
7.10	Integração com Contexto de Utilizador e Documentos Proprietários	27
8	Testes e Validação	28
8.1	Estratégia Geral de Testes	28
8.2	Testes de Componentes Isolados	28
8.3	Testes da Pipeline RAG Completa	29
8.4	Validação de Geração de Documentos	29
8.5	Testes de Matriz de Rastreabilidade	30
8.6	Testes de Validação de Dados e Segurança	30
8.7	Validação com Caso de Estudo Real	31

8.8	Limitações Identificadas e Lições Aprendidas	31
8.9	Validação de Performance e Escalabilidade	32
8.10	Processo de Validação Contínua	32
9	Desafios Técnicos Encontrados e Resoluções	33
9.1	Mitigação de Alucinações em Modelos de Linguagem	33
9.2	Qualidade de Retrieval Semântico com Embeddings	34
9.3	Processamento de Documentos Regulatórios em PDF	35
9.4	Determinação de Intenção Regulatória Correcta	35
9.5	Prompting Adaptativo para Diferentes Intenções	36
9.6	Rastreabilidade Completa sem Impactar Performance	37
9.7	Gestão de Estado em Conversas Longas	37
9.8	Compatibilidade e Portabilidade de Componentes	38
9.9	Validação de Campos Estruturados em Templates	39
9.10	Consistência de Citações nas Respostas	39
9.11	Gestão de Escala e Performance	40
10	Exemplo Prático	41
11	Resultados	44
12	Trabalho Futuro	46
12.1	Streaming das Respostas	46
12.2	Indicador Visual Durante o Retrieval	46
12.3	Refinamento Contínuo dos Prompts Regulatórios	47
12.4	Fecho do Ciclo de Aprendizagem via Fine-tuning do Modelo Local	48
12.5	Suporte a Vários Idiomas	49
13	Declaração de Utilização de Inteligência Artificial	51
14	Referências	52

Lista de Figuras

1	Visão geral da arquitetura do sistema.	10
2	Ilustração do fluxo do processamento da questão e revisão por especialista.	22
3	Interface de Chat do Utilizador (BridgeMedAI) — Apresenta a interface principal de conversação do utilizador com o assistente, demonstrando a submissão de uma dúvida regulatória e a resposta estruturada do sistema.	41
4	Interface de Pré-Validação Automática e Avaliação — Ilustra o painel com o resultado da pré-validação automática (consistência e similaridade) e a secção para o utilizador registar notas de feedback.	42
5	Painel de Gestão de Pedidos de Revisão do Especialista — Mostra a perspectiva interna do especialista, permitindo analisar perguntas pendentes, classificar erros e submeter observações de correção.	42
6	Histórico de Revisão e Feedback do Especialista — Detalha a interface de acompanhamento do utilizador, exibindo o parecer técnico e o estado de validação emitido pelo especialista humano.	43

1 Introdução

A integração de sistemas de Inteligência Artificial (IA) em dispositivos médicos marcou o início de uma era na medicina personalizada e na eficiência dos cuidados de saúde. No entanto, este avanço progride a uma velocidade superior à adaptação dos processos de certificação. O presente projeto nasce da necessidade de responder à elevada complexidade regulatória que as organizações do setor enfrentam atualmente.

1.1 Contextualização do Problema

O principal obstáculo identificado é a existência de múltiplos enquadramentos legais sobrepostos. No caso dos dispositivos médicos com componentes de inteligência artificial, os fabricantes devem cumprir simultaneamente o Medical Device Regulation (MDR), o AI Act e as normas ISO/IEC. Esta realidade traduz-se em três desafios fundamentais:

- **Ineficiência:** A gestão de requisitos sobrepostos conduz à duplicação de esforços e documentação redundante.
- **Rastreabilidade:** A dificuldade em estabelecer uma ligação auditável entre requisitos, design e evidências de validação.
- **Risco:** A complexidade aumenta a probabilidade de falhas em auditorias e atrasos na colocação de produtos no mercado.

Perante este cenário, torna-se evidente a necessidade de ferramentas capazes de centralizar requisitos regulamentares, automatizar parcialmente tarefas documentais e garantir mecanismos consistentes de rastreabilidade. A crescente complexidade associada aos processos de compliance demonstra que abordagens puramente manuais se tornam cada vez menos sustentáveis, especialmente em organizações que desenvolvem dispositivos médicos com componentes de Inteligência Artificial.

1.2 A Solução: BridgeMedAI

O BridgeMedAI é uma plataforma inteligente concebida para atuar como ponte entre a engenharia de software, a gestão documental e a conformidade regulatória em dispositivos médicos com e sem componentes de Inteligência Artificial. O principal objetivo da solução é apoiar empresas MedTech na adaptação às exigências impostas pelo MDR, AI Act e normas ISO/IEC, reduzindo a complexidade operacional associada aos processos de compliance e certificação.

A plataforma foi desenvolvida para:

1. Sistematizar e mapear requisitos regulamentares e normativos provenientes do MDR, AI Act e normas ISO aplicáveis;
2. Estruturar mecanismos de rastreabilidade entre requisitos, evidências, testes e documentação técnica;
3. Otimizar a preparação documental através de assistência contextualizada baseada em modelos de linguagem de grande escala (LLMs);
4. Simplificar processos de análise regulamentar através de mecanismos de Retrieval-Augmented Generation (RAG), garantindo fundamentação em documentação previamente indexada;
5. Apoiar equipas regulatórias e técnicas na preparação para auditorias e processos de certificação.

Contudo, para garantir o nível de fiabilidade e rigor exigido no setor biomédico, o BridgeMedAI não opera como um sistema totalmente autónomo. A solução segue uma abordagem híbrida de prestação de serviços (Software + Serviços Profissionais), incorporando o princípio de supervisão humana em todas as etapas críticas do processo.

Neste modelo, a plataforma funciona como um acelerador tecnológico para extração de requisitos, organização documental e pré-geração de conteúdos técnicos, enquanto especialistas regulatórios e engenheiros qualificados permanecem responsáveis pela revisão, validação e homologação final de todos os outputs produzidos pelo sistema. Adicionalmente, a solução prevê suporte especializado através de auditorias simuladas, acompanhamento técnico e formação avançada, permitindo às organizações clientes melhorar os seus processos internos de compliance e preparação regulatória.

Desta forma, o BridgeMedAI procura combinar automação inteligente com supervisão humana especializada, contribuindo para aumentar a eficiência dos processos de conformidade, reduzir redundâncias documentais e mitigar riscos associados à utilização de Inteligência Artificial em contextos clínicos e regulatórios críticos.

2 Estado da arte, ferramentas e tecnologias

2.1 Estado da arte

A revisão da literatura destaca trabalhos recentes sobre a interpretação do AI Act com apoio de LLMs e sobre a geração de especificações alinhadas com normas. Estes contributos reforçam a necessidade de soluções que combinem conformidade regulatória, rastreabilidade e automação assistida.

2.2 Ferramentas e Tecnologias

O sistema é suportado por uma pilha tecnológica que inclui React 19 e Vite no frontend (com a utilização de React Router para gestão dinâmica de rotas de utilizador), FastAPI com validação estrita via Pydantic no backend, SQL Server acedido através de pyodbc (com recurso ao ODBC Driver 17) para persistência relacional, armazenamento local dedicado para ficheiros de evidências e ChromaDB como vector store nativa para o pipeline de RAG. Adicionalmente, o ecossistema local do Ollama é utilizado para fornecer capacidades linguísticas avançadas sem dependências externas.

2.3 RAG e mitigação de alucinações

O uso de Retrieval-Augmented Generation (RAG) permite reduzir respostas infundadas ao ancorar a geração em documentos e evidências recuperadas previamente. Num domínio regulado como o dos dispositivos médicos, esta abordagem é crítica para evitar alucinações e melhorar a confiança no conteúdo produzido, garantindo que a informação gerada é suportada por fontes verificáveis.

3 Levantamento de requisitos e arquitetura

3.1 Levantamento de Requisitos

Público-alvo

O BridgeMedAI destina-se aos seguintes utilizadores:

- Profissionais na área regulatória que trabalham enquanto consultores que auxiliam empresas externas, especificamente na temática dos dispositivos médicos que incluem funcionalidades de IA.
- Engenheiros na área regulatória, ou equipas de desenvolvimento de dispositivos médicos, numa PME na área MedTech.

Requisitos funcionais

- Mapear requisitos normativos provenientes de MDR, AI Act, GDPR, ISO 14971 e IEC 62304.
- Gerar uma matriz de rastreabilidade (RTM) entre requisitos, evidências e artefactos.
- Apoiar a geração de rascunhos de documentação técnica com assistência de IA.
- Permitir validação e revisão humana antes da utilização final do conteúdo.

Requisitos funcionais (Cont.)

- Mapear requisitos normativos provenientes de MDR, AI Act, GDPR, ISO 14971 e IEC 62304.
- Gerar uma matriz de rastreabilidade (RTM) entre requisitos, evidências e artefactos.
- Apoiar a geração de rascunhos de documentação técnica com assistência de IA.
- Permitir validação e revisão humana antes da utilização final do conteúdo.

Requisitos não funcionais

- Garantir consistência e fiabilidade da informação produzida.
- Reduzir a probabilidade de geração de conteúdo incorreto ou não suportado.
- Manter a solução modular e escalável.
- Facilitar auditoria, manutenção e rastreabilidade futura.

Matriz de rastreabilidade

A matriz de rastreabilidade relaciona requisitos, evidências, normas e artefactos gerados pelo sistema, permitindo identificar lacunas, dependências e pontos de validação ao longo do processo de conformidade.

3.2 Arquitetura do Sistema

A arquitetura organiza a interação entre o utilizador, a camada de apresentação, a lógica de negócio, o armazenamento de dados e o módulo de IA. A separação por camadas permite modularidade, rastreabilidade e controlo sobre os conteúdos produzidos.




Figura 1: Visão geral da arquitetura do sistema.

4 Implementação Técnica

4.1 Arquitetura em Camadas

O BridgeMedAI segue uma arquitetura em camadas com separação clara de responsabilidades, permitindo modularidade, rastreabilidade e facilidade de manutenção. O sistema é composto por:

- **Camada de Apresentação (Frontend):** A interface de utilizador foi desenvolvida com React 19 e Vite, utilizando React Router para navegação entre componentes. A arquitetura frontend organiza-se em componentes reutilizáveis que refletem os diferentes fluxos de utilizadores (Customer, Specialist, Admin). A comunicação com o backend é realizada através de pedidos HTTP REST, garantindo uma separação limpa entre lógica de apresentação e lógica de negócio.
- **Backend API:** O backend foi desenvolvido utilizando FastAPI com validação de dados através de Pydantic. O sistema expõe endpoints REST organizados por domínios funcionais (autenticação, regulatório, RAG, gestão de documentos). O FastAPI é executado com Uvicorn.
- **Camada de Dados:** O sistema integra duas camadas de persistência complementares: SQL Server para dados estruturados (utilizadores, dispositivos, submissões, matriz de rastreabilidade) e ChromaDB como vector store para a camada RAG.

4.2 Serviços Principais do Backend

O backend foi estruturado em módulos de serviço especializados, cada um responsável por um domínio específico:

- **Serviço de Autenticação (`api_auth_service.py`):** Implementa mecanismos de autenticação baseados em JWT, com suporte a múltiplos papéis (Customer, Specialist, Admin). O serviço gerencia o registo, geração e validação de tokens, aprovação de especialistas por administradores e controlo de permissões.
- **Serviço RAG (`api_rag_service.py` e `rag_chromadb_service.py`):** Implementa o pipeline de Retrieval-Augmented Generation, alimentando-se de documentos regulatórios em chunks semânticos no ChromaDB. Aquando de uma pergunta, analisa a intenção, gera variantes da query, realiza a procura semântica e injeta o contexto num prompt estruturado enviado ao Ollama Local, aplicando filtros contra alucinações.
- **Serviço Regulatório (`api_regulatory_service.py`):** Organiza o fluxo de análise de dispositivos médicos através da colheita estruturada de dados, mapeamento de requisitos MDR, AI Act e ISO/IEC, e geração da matriz de rastreabilidade (RTM).

- **Serviço de Documentos de Utilizador (api_user_documents_service.py):** Permite a submissão, armazenamento e indexação opcional de documentação técnica de suporte no ChromaDB.
- **Serviço de Matriz de Validação (api_user_validation_service.py):** Constrói dinamicamente a matriz que correlaciona requisitos identificados, evidências submetidas e validações efetuadas.

4.3 Persistência de Dados

SQL Server: A base de dados relacional centraliza toda a informação estruturada através de uma camada de abstração (api_db.py) que gera conexões via pyodbc com o ODBC Driver 17, context managers para controlo de rollback automático e suporte a autenticação corporativa (Trusted Connection).

ChromaDB: O vector store suporta operação local em Modo Persistente (armazenamento local de embeddings e metadados) ou via Modo HTTP (ligação ao servidor remoto na porta 8002). Gere duas coleções principais: regulations_chunks e user_documents_chunks.

4.4 Integração com LLM e Embeddings

Ollama Local: O sistema utiliza o Ollama para executar modelos de linguagem localmente no servidor do projeto, garantindo total privacidade e eliminando a dependência de APIs de terceiros. Suporta modelos dedicados para Chat e Embeddings com vetores configuráveis de dimensionalidade 384 ou 768.

Tratamento de Alucinações: Implementa-se um mecanismo de baixa confiança (low confidence fallback) que valida se a resposta respeita as regras estritas de citação e contexto injetado no prompt. Caso detete respostas especulativas ou não fundamentadas, devolve um aviso de baixa confiança e solicita a intervenção de um especialista humano.

4.5 Autenticação e Autorização

O sistema assenta num modelo de controlo de acesso baseado em papéis (RBAC):

Customer: Acesso à submissão de novos dispositivos e consulta da sua documentação.

Specialist: Permissão de visualização e revisão de submissões pendentes em fila de auditoria.

Admin: Gestão global da plataforma e aprovação cadastral de novos especialistas.

4.6 Fluxo de Processamento Completo

O ciclo de vida completo de uma análise de conformidade e tratamento de consultas RAG corre de forma integrada ao longo das camadas descritas na subsecção 4.1, partindo da validação do token JWT do utilizador na API REST até à geração da resposta fundamentada no Ollama Local e auditoria final com as respetivas fontes normativas associadas.

4.7 Escalabilidade e Modularidade

A arquitetura foi concebida de raiz sem acoplamento direto: os serviços comunicam por interfaces bem delimitadas, o backend de vetores pode ser facilmente migrado para outras soluções, os modelos locais do Ollama podem ser trocados transparentemente e o armazenamento de ficheiros está preparado para integração futura com cloud storage.

5 Análise Pormenorizada de Requisitos

5.1 Enquadramento dos Requisitos Regulatórios

O BridgeMedAI foi concebido para integrar e mapear requisitos provenientes de múltiplos enquadramentos regulatórios que se sobrepõem e, frequentemente, definem obrigações mútuas para fabricantes de dispositivos médicos com componentes de Inteligência Artificial. Os quatro pilares regulatórios principais são:

Medical Device Regulation (MDR – Regulamento UE 2017/745): O MDR é o enquadramento primário para a conformidade de dispositivos médicos na Europa. Define obrigações fundamentais relacionadas com:

- Classificação de dispositivos (Classes I, IIa, IIb, III)
- Avaliação clínica (Clinical Evaluation Report – CER, Post-Market Clinical Follow-up – PMCF)
- Gestão de risco (Risk Management File segundo a norma ISO 14971)
- Rastreabilidade e vigilância pós-mercado
- Documentação técnica e qualidade de fabrico

Artificial Intelligence Act (AI Act – Regulamento UE 2024/1689): O AI Act sobrepõe-se ao MDR para dispositivos que integram sistemas de IA de elevado risco. Impõe requisitos adicionais e complementares relacionados com:

- Classificação de risco de IA (alto risco, risco limitado, risco mínimo)
- Transparência e explicabilidade de algoritmos
- Monitorização de desempenho em produção
- Documentação de conformidade com o AI Act
- Avaliação de conformidade para IA de elevado risco

Normas ISO/IEC Harmonizadas: As normas ISO/IEC fornecem especificações técnicas detalhadas e metodologias para alcançar conformidade MDR. As normas mais relevantes incluem:

- **ISO 14971** (Risk Management): Define a metodologia FMEA para identificação de perigos (hazards), análise de risco e implementação de controlos.
- **IEC 62304** (Software Life Cycle): Especifica processos de ciclo de vida para software médico.
- **IEC 62366** (Usability): Define requisitos de engenharia de usabilidade.
- **ISO 27001** (Cybersecurity): Certificação de sistemas de gestão de segurança da informação.

5.2 Estrutura de Mapeamento de Requisitos

O BridgeMedAI implementa um sistema integrado de mapeamento de requisitos através de três camadas complementares:

Camada 1: Registo Canónico de Templates (registry.json): O sistema mantém um registo centralizado de mais de 20 templates normalizados, cada um mapeado para requisitos específicos de enquadramentos regulatórios. Cada template contém metadados associados ao identificador único, objetivos, secções obrigatórias e mapeamentos cruzados normativos. Este registo permite ao sistema compreender:

- Que normas/regulamentos cada template satisfaz;
- Que campos podem ser preenchidos automaticamente vs. requerem um especialista humano;
- Dependências entre documentos (por exemplo, o Plano de Gestão de Risco precede o Ficheiro de Gestão de Risco);
- Cadeia de transformação de documentos (por exemplo, o Ficheiro de Risco alimenta o Relatório de Avaliação Clínica).

Camada 2: Indexação Regulatória em Base de Dados: O pipeline de ingestão (regulations_and_WriteInTables.py) processa documentos regulatórios oficiais em PDF e estrutura-os em SQL Server numa hierarquia de três níveis organizativos estruturados de forma estrita de acordo com a raiz regulatória do documento original: **Enquadramento Principal** (MDR, AI Act), seguido pelos respetivos **Artigos ou Capítulos**, e finalizando nos respetivos **Considerandos, Alíneas ou Anexos Técnicos**. Esta estrutura permite:

- Recuperação precisa de obrigações específicas via RAG;
- Atribuição de citações exatas (ex: “Artigo 10 do MDR”);
- Evitar conflito entre interpretações ao manter uma origem única de dados.

Camada 3: Grafo de Fluxo Documental (Workflow Engine): O módulo `api_workflow_engine.py` organiza os templates em workflows predefinidos baseados no perfil regulatório do dispositivo, definindo de forma estrita uma **Cadeia sequencial de tarefas documentais, condições de transição lógica de estado e regras de aprovação humana**. O sistema recomenda automaticamente que workflow aplicar com base no perfil do dispositivo (classe MDR, presença de software, integração de IA).

5.3 Exemplo Concreto de Mapeamento: Requisitos para Dispositivo com IA

Para ilustrar como os requisitos são mapeados, consideramos um dispositivo médico classificado como **Classe IIb com algoritmo de IA de elevado risco**:

Requisito 1: Avaliação de Risco de IA

Enquadramento	Requisito Específico	Implementação BridgeMedAI	Template	Auto-Fill
AI Act	Art. 9	Mitigação de risco em IA de Elevado Risco	TMP-AI-01	Sim
MDR	Anexo I (GSPR)	Conformidade com segurança essencial	TMP-TD-03	Parcial
ISO 14971	Secção 5	Identificação de hazards de IA	TMP-RM-01	Não

O sistema mapeia automaticamente o fluxo onde a pergunta do utilizador é analisada via RAG, e os requisitos aplicáveis são recuperados simultaneamente do MDR e AI Act. A matriz de rastreabilidade cria ligações cruzadas relacionando o **Requisito Regulatório Original**, a **Métrica ou Critério de Aceitação Técnico**, a **Evidência gerada (Documento Técnico)** e o **Histórico de Revisão Humana**.

Requisito 2: Documentação de Conformidade com GDPR

Framework	Requisito	Mapeamento
GDPR Art. 32	Segurança de dados pessoais	ISO 27001 – Information Security Management
AI Act Art. 14	Documentação técnica	TMP-SW-02 + TMP-SW-05 (Software Documentation)
MDR Art. 123	Ficheiro Técnico	Integração com TMP-TD-03 (GSPR)

5.4 Matriz de Rastreabilidade (Traceability Matrix – RTM)

O serviço `api_traceability_service.py` constrói a matriz central que relaciona a totalidade estrutural entre os **Requisitos normativos injetados**, as **Funcionalidades de Software mapeadas**, os **Casos de Teste e Validação executados** e os **Ficheiros de Evidência documental anexados**.

A RTM rastreia de forma atômica:

- Identificadores únicos para cada requisito normativo;
- Origem (artigo/secção/ponto específico do regulamento);
- Norma harmonizada que implementa o requisito;
- Evidência de conformidade (documento/teste/validação que prova conformidade);
- Status (OK / Parcialmente Completo / Não Conforme / Sob Revisão).

5.5 Dependências de Documentos e Fluxo Regulatório

O sistema modela dependências entre documentos como um grafo dirigido, garantindo que a documentação é elaborada na ordem correta, estabelecendo uma hierarquia estrita onde a **Especificação de Intended Purpose** precede a **Análise de Risco**, que por sua vez valida a **Arquitetura de Software** e alimenta o **Plano de Avaliação Clínica**.

O sistema impede erros comuns como:

- Submissão de Ficheiro de Risco sem ter primeiro definido o Plano de Risco;
- Avaliação Clínica sem requisitos do utilizador definidos;
- Teste de software sem arquitetura documentada.

5.6 Campos Auto-Preenchidos vs. Expertise Humana Obrigatória

O sistema diferencia rigorosamente as responsabilidades operacionais:

Campos Auto-Preenchíveis: Informação técnica factual (ex: `intended_purpose` do dispositivo), metadata regulatória (ex: classe MDR do dispositivo), referências cruzadas automáticas (ex: hazards já identificados) e templates normalizados com placeholders.
Vantagem: Reduz tempo de execução, garante consistência entre documentos.

Campos Que Requerem Expertise Humana: Análises clínicas (appraisal de evidência clínica), análise de risco (identificação de hazards, estimar severidade/probabilidade), validação de conformidade (revisão de que controlos mitigam efetivamente o risco) e decisões regulatórias críticas (ex: conclusão de equivalência de dispositivo).

Tipo de Conteúdo	Método de Preenchimento	Nível de Revisão
Metadados do Sistema	Automação Baseada em Submissão	Validação de Esquema
Cláusulas de Risco	Geração RAG + Proposta de Mitigação	Revisão Obrigatória por Especialista
Conclusão Clinical	Introdução Manual Humana	Homologação e Assinatura Digital

5.7 Integração de GDPR e Cybersecurity

Para dispositivos que processam dados pessoais ou integram componentes com IA:

GDPR Requirements:

- Processamento de dados pessoais: Documentação de Data Processing Agreement;
- Direitos dos utilizadores: Mecanismos de consentimento e acesso;

Cybersecurity (IEC 62304):

- Identificação de assets críticos (ex: algoritmo de IA, base de dados clínica);
- Ameaças e vulnerabilidades (ex: model poisoning, adversarial attacks);
- Controlos técnicos (ex: encriptação, autenticação forte, registo de auditoria).

O mapeamento unifica estas frentes garantindo que nenhuma vulnerabilidade cibernética comprometa a segurança clínica exigida pelo MDR.

6 Fluxos de Utilizador

O BridgeMedAI foi concebido para suportar três papéis distintos de utilizador, cada um com responsabilidades, permissões e fluxos de trabalho específicos. Esta estrutura implementa o princípio de supervisão humana (Human-in-the-Loop), onde a automação é sempre supervisionada por especialistas humanos em etapas críticas.

6.1 Definição de Papéis e Permissões

O sistema implementa um modelo de Controlo de Acesso Baseado em Papéis (RBAC) com três papéis principais:

- **Utilizador:** É um utilizador que fica ativo imediatamente após o registo e é responsável por descrever dispositivos, submeter documentação e receber análises de conformidade. O seu acesso é estritamente limitado aos seus próprios dados de conformidade.
- **Specialist:** É um profissional qualificado cuja conta fica inicialmente em estado pendente e requer aprovação formal por um administrador. As suas responsabilidades incluem rever análises de conformidade, validar documentação e aprovar conformidade regulatória, tendo acesso a uma fila de trabalho global de todas as submissões.
- **Admin:** É criado através de um convite único e possui responsabilidades de gestão de especialistas, aprovações e controlo geral do sistema, com acesso completo a todas as funcionalidades da plataforma.

A autenticação do sistema utiliza JSON Web Tokens (JWT) para sessões seguras. Cada token contém informação sobre o identificador único do utilizador, email, papel (customer, specialist ou admin), status (ativo, pendente ou rejeitado) e o tempo de validade. Os tokens têm uma validade de doze horas, após o qual, o utilizador necessita de se re-autenticar. Todas as operações críticas são auditadas e rastreadas na matriz de rastreabilidade centralizada.

6.2 Fluxo do Customer (Utilizador Cliente)

O customer representa uma organização fabricante de dispositivos médicos que necessita de conformidade regulatória. O seu fluxo divide-se em quatro etapas principais:

1. Registo e Integração inicial: O utilizador acede ao frontend e regista-se como cliente. Preenche um formulário com email único, password com requisitos mínimos (pelo menos oito caracteres, incluindo uma letra e um número) e nome completo. O sistema cria um registo na base de dados via endpoint `POST /auth/register-user` com papel customer e status ativo, direcionando-o de imediato para o dashboard.

2. Consulta RAG e Chatbot Inteligente: Após o login, o cliente pode colocar questões em linguagem natural. Ao submeter uma pergunta ao endpoint `/chat/answer`, o backend faz a triagem da intenção, recupera fragmentos indexados no ChromaDB do MDR, AI Act ou normas ISO, e gera uma resposta fundamentada no Ollama Local. A interação é guardada na matriz com tipo chat, devolvendo citações exatas das fontes normativas.

3. Fluxo Regulatório Guiado: Consiste em três passos sequenciais estruturados:

- a) *Descrição do Dispositivo:* O cliente detalha o produto, finalidade prevista e presença de IA. O backend analisa os dados e deduz a classe de risco MDR (I, IIa, IIb ou III), o enquadramento no AI Act (sem risco, risco limitado ou risco elevado) e as respectivas obrigações pré e pós-mercado.
- b) *Recolha Documental:* O sistema invoca um template, omitindo os dados já conhecidos da conversa e agrupando dinamicamente as novas perguntas por blocos lógicos (fabricante, produto, dados clínicos). Campos que exigem um especialista humano ficam sinalizados visualmente.
- c) *Geração de Conteúdo:* O sistema compila os dados e exporta um ficheiro em formato Word (.docx). Os dados automáticos surgem em negrito e as lacunas humanas com o aviso “Preencher manualmente”.

4. Submissão para Auditoria: Após rever e afinar o documento gerado, o customer submete o processo. O sistema regista a submissão com um identificador único, define o estado como “submitted” e fornece informação sobre a sua posição na fila global e o tempo estimado de revisão.

6.3 Fluxo do Specialist (Utilizador Especialista Regulatório)

O specialist atua como o validador humano das propostas da plataforma. O seu fluxo operacional compreende as seguintes fases:

1. Registo e Submissão de Credenciais: O especialista submete um formulário no qual indica a sua área de especialidade, a instituição e anexa credenciais em PDF ou imagem (hasta 10 MB), que são guardados em `/uploads/credentials/`. O "status" inicial é definido como pendente.

2. Homologação Administrativa: Um administrador analisa as evidências profissionais. Se aprovado, o status passa a ativo e o especialista ganha acesso ao sistema. Em caso de rejeição, pode iniciar um processo de resubmissão de credenciais com justificações adicionais.

3. Gestão da Fila de Trabalho Global: O especialista verifica a lista de submissões pendentes, ordenadas por prioridade, exibindo o cliente, classe MDR e data de entrada.

4. Revisão Técnico-Regulatória: Ao selecionar um caso, o painel exibe as métricas de preenchimento (campos automáticos vs. manuais) e a RTM. O especialista descarrega o Word e preenche campos exclusivos de discernimento humano, como o appraisal de dados clínicos, análise de benefício-risco e parecer final de segurança.

5. Decisão de Conformidade: O fluxo conclui-se com duas ações possíveis: a Aprovação (muda o estado para aprovado, emite um ID de homologação e notifica o cliente) ou o Pedido de Alterações (sinaliza as falhas com severidade baixa, média ou alta, estipulando um prazo padrão de dez dias para correção).

6.4 Fluxo do Admin (Administrador do Sistema)

O admin detém o controlo total da governança da plataforma através das seguintes frentes de trabalho:

1. Inicialização de Segurança: Por motivos de segurança, não há auto-registo de administradores. O primeiro perfil administrativo é criado diretamente no servidor através de um script isolado de inicialização (bootstrap).

2. Gestão de Especialistas: O painel administrativo expõe a fila de validação profissional, permitindo o preview e download dos diplomas anexados pelos especialistas antes de emitir o parecer de aprovação ou rejeição.

3. Convites Administrativos: Para fornecer permissões, um administrador pode gerar convites de acesso baseados no email do destinatário. O sistema cria um token único com uma validade de 48 horas para permitir o registo do novo administrador.

4. Auditoria Global do Sistema: O painel disponibiliza filtros de controlo por papel e status dos utilizadores, métricas de desempenho por especialista e o acesso à árvore completa da matriz de rastreabilidade para inspeção de fluxos.

6.5 Ciclo de Vida Completo de Uma Submissão

O percurso integrado de um processo cumpre a seguinte ordem cronológica:

Registo do Cliente → Consulta RAG prévia no Chat → Submissão da Descrição Técnica do Dispositivo → Triagem Automática de Risco e Enquadramento → Questionário Dinâmico do template escolhido → Exportação de Rascunho Word → Ajuste Manual do Fabricante → Submissão na Fila de Espera → Avaliação do Especialista → Desfecho Final (Aprovação ou Pedido de Correção).

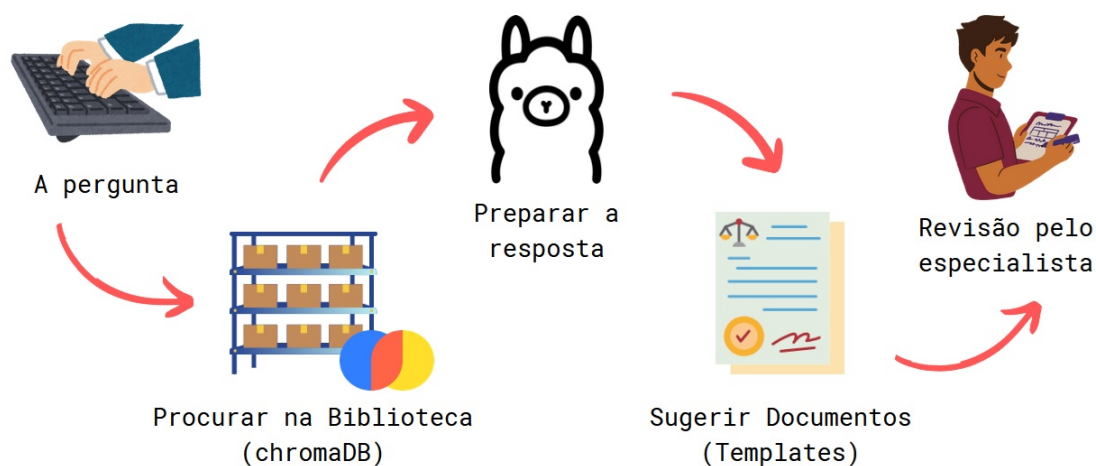


Figura 2: Ilustração do fluxo do processamento da questão e revisão por especialista.

6.6 Rastreabilidade e Auditoria

Para efeitos de conformidade com os requisitos de auditoria do MDR e AI Act, todas as transições de estado do sistema são persistidas de forma imutável. A Tabela 1 detalha a estrutura de captura de eventos gerada pelo serviço central de logs.

Tabela 1: Mapeamento de Eventos e Dados de Auditoria

Módulo de Origem	Tipo de Interação	Dados Registrados na Matriz
Chatbot RAG	chat	Pergunta, resposta gerada, chunks de contexto e IDs das fontes.
Serviço Regulatório	analysis	Descrição do dispositivo, classe MDR, regras e obrigações deduzidas.
Gestor de Documentos	generation	Caminho do ficheiro, percentagem de preenchimento e placeholders pendentes.
Fila de Trabalho	submission	Especialista associado, timestamp de entrada e nível de prioridade.
Painel do Especialista	review	ID do validador, notas clínicas de benefício-risco e assinatura digital.

7 Detalhes da Integração de Retrieval-Augmented Generation (RAG)

O Retrieval-Augmented Generation (RAG) é a componente central que permite ao Bridge-MedAI gerar respostas fundamentadas em documentação regulatória verificada, reduzindo significativamente as alucinações que são um risco crítico em contextos regulatórios. A implementação do RAG segue uma arquitetura rigorosa composta por múltiplas etapas de processamento, otimizadas para o domínio de conformidade regulatória em dispositivos médicos com IA.

7.1 Visão Geral da Pipeline RAG

A pipeline RAG executa um fluxo bem definido que transforma uma pergunta em linguagem natural numa resposta fundamentada. Quando um utilizador submete uma questão (ex: *“Que requisitos de segurança se aplicam a um termómetro com IA?”*), o sistema aciona uma sequência estruturada: análise da intenção da pergunta, recuperação semântica de fragmentos relevantes, ranking e eliminação de resultados duplicados, construção de contexto estruturado e, finalmente, geração da resposta pelo modelo de linguagem.

Ao contrário de abordagens genéricas, a implementação inclui regras do domínio regulatório que validam se os fragmentos recuperados são realmente aplicáveis ao dispositivo sob análise. O sistema conta ainda com múltiplos níveis de fallback para indicar de forma transparente as situações em que o contexto disponível seja insuficiente para responder com confiança.

7.2 Ingestão e Indexação de Documentação Regulatória

A indexação da documentação é executada de forma offline através do módulo `regulations_and_WriteInTables.py`, encarregue de processar e estruturar os ficheiros originais em PDF:

- **Extração de Conteúdo:** Com o recurso à biblioteca PyMuPDF, o sistema extrai o texto dos regulamentos de referência (MDR, AI Act) e das normas (ISO 13485, ISO 14971, IEC 62304), retendo a indexação por capítulos, artigos e secções.
- **Segmentação Semântica (Chunking):** Após a normalização e limpeza textual, o conteúdo é dividido em blocos de tamanho controlado (tipicamente até 512 tokens). Cada bloco recebe metadados descritivos e uma etiqueta inequívoca de referência no campo `citation_label` (ex: *“MDR Artigo 10”*).

- **Persistência Híbrida:** Os metadados estruturados e a hierarquia legal são mapeados na base de dados relacional SQL Server. Em paralelo, são gerados vetores numéricos de 384 ou 768 dimensões com os modelos locais do Ollama, guardados numa coleção dedicada designada `regulations_chunks` no ChromaDB.

7.3 Análise da Intenção e Detecção do Perfil

O módulo `rag_router_utils.py` expõe a função `analyze_question` para decifrar a intenção regulatória do utilizador por via de mapeamento semântico e palavras-chave. As categorias mapeadas englobam:

Classe de Intenção	Foco Operacional da Consulta
<code>document_generation</code>	Pedidos de automatização documental estruturada.
<code>regulatory_scope</code>	Delimitação do âmbito e aplicação jurídica dos regulamentos.
<code>requirement_lookup</code>	Extração de um requisito normativo ou artigo isolado.
<code>classification_risk</code>	Determinação da classe de risco clínico via Anexo VIII do MDR.
<code>manufacturer_obligations</code>	Levantamento dos deveres legais do fabricante técnico.
<code>conformity_procedure</code>	Passos processuais para obtenção de marcação CE.
<code>device_qualification</code>	Avaliação de enquadramento como dispositivo médico ou acessório.
<code>ai_high_risk</code>	Triagem de critérios de alto risco no âmbito do AI Act.

A par da intenção, o sistema extrai o perfil técnico do dispositivo (ex: se é invasivo, se integra software ou modelos de IA), permitindo ajustar o foco da recuperação e priorizar normas específicas como a IEC 62304 ou o articulado do AI Act.

7.4 Construção de Variantes de Query e Retrieval Semântico

Para expandir a cobertura do algoritmo de busca e contornar variações de vocabulário, o método `build_query_variants` gera reescritas semânticas da pergunta original. Estas variantes são convertidas em vetores e submetidas a uma pesquisa de similaridade por cosseno no ChromaDB, com um parâmetro de recuperação inicial (K) configurado para recolher até 40 fragmentos por variante. Os resultados são agregados e os blocos que demonstram relevância transversal recebem prioridade no alinhamento final.

7.5 Ranking e Ajuste de Scores com Heurísticas do Domínio

Para lá da proximidade vetorial bruta, o módulo `adjust_score` refina a ordenação através de regras de negócio:

- **Impulso Temático (Boost):** Incrementa a pontuação de documentos associados à intenção (ex: beneficia artigos do MDR se o utilizador focar obrigações de fabrico).
- **Eliminação de duplicados:** Consolida blocos sobrepostos com base no `citation_label`, retendo apenas a amostra com maior correspondência.
- **Filtragem Estrita:** Aplica-se um limiar de corte absoluto de 0.30 e um limiar relativo de 80% face ao score mais alto da consulta. Fragmentos aceites são truncados a um máximo de 1400 caracteres para mitigar ruído no contexto.

7.6 Construção de Contexto Estruturado

Os fragmentos finais são empacotados num bloco de texto coerente com delimitadores bem definidos de origem (número de fonte, documento, citação, páginas e conteúdo). Esta formatação explícita permite que o modelo de linguagem, pré-condicionado via técnicas de aprendizagem com poucos exemplos (few-shot learning), utilize diretamente os marcadores de citação jurídica mapeados (ex: “*conforme MDR Artigo 10*”) em vez de indexadores genéricos de bloco.

7.7 Construção de Prompt Estruturado e Adaptação por Intenção

O prompt final consolida o system prompt base, as instruções específicas por intenção e o par pergunta-contexto. O system prompt dita regras imperativas de conduta: responder exclusivamente com base no contexto, proibir a criação de artigos ou anexos fictícios, usar português de Portugal e acionar o recuo explícito de falta de informação se o bloco for insuficiente.

Os prompts de intenção tratam desvios típicos observados em fase de testes: evitam a assimilação indevida da Classe I no MDR para dispositivos não invasivos, previnem a fusão concetual entre avaliação clínica e PMCF, e resguardam os fluxos de procedimentos de conformidade para não derivarem autonomamente para classificações de risco isoladas.

7.8 Geração de Resposta com Ollama e Mitigação de Alucinações

O prompt integrado é despachado localmente para o motor do Ollama, operando por padrão modelos como o `qwen2.5:7b-instruct`. A mitigação de alucinações atua em três

camadas: a restrição física das fontes injetadas, as diretivas negativas no prompt e a validação posterior do texto produzido. Caso o sistema identifique afirmações desprovidas de citação ou se a similaridade computada for inferior a 0.40, é ativado o recuo de baixa confiança, sugerindo a intervenção direta de um especialista regulatório humano.

7.9 Rastreabilidade e Auditoria da Pipeline RAG

Cada ciclo da pipeline RAG armazena uma pista de auditoria imutável na matriz de rastreabilidade. A estrutura engloba o ID exclusivo do traço, o ID do utilizador, a pergunta original, as variantes processadas, os scores de similaridade, a resposta final gerada, as citações extraídas e o estado de validação humana. Este nível de detalhe permite a um auditor recuar até ao bloco exato de texto ou ficheiro SQL/PDF que justificou determinada indicação regulatória na plataforma.

7.10 Integração com Contexto de Utilizador e Documentos Proprietários

Através do módulo `api_user_documents_service`, o BridgeMedAI permite a indexação de ficheiros privados do utilizador (ex: protocolos de testes, dados clínicos) numa coleção autónoma do ChromaDB designada `user_documents_chunks`.

A pipeline executa uma busca paralela mas aplica uma hierarquia estrita de prevalência legal: a documentação oficial (MDR, AI Act, normas ISO) sobrepõe-se sempre aos regulamentos internos. Sempre que se detete uma divergência técnica, o sistema sinaliza o conflito emitindo um aviso explícito ao fabricante:

“Este ponto do seu documento entra em conflito com IEC 62304:2006 Secção 5.

A norma IEC 62304 prevalece em contexto regulatório.”

8 Testes e Validação

A estratégia de testes e validação do BridgeMedAI foi projectada para garantir fiabilidade crítica em contexto regulatório, onde erros em conformidade podem resultar em consequências significativas para as organizações clientes. A abordagem combina testes unitários de componentes isolados, testes de integração entre subsistemas, e validação funcional com cenários reais de dispositivos médicos.

8.1 Estratégia Geral de Testes

O projeto segue uma estratégia em camadas onde cada camada de teste valida diferentes aspectos do sistema:

1. **Testes de Sanidade:** Verificação dos componentes críticos individuais, garantindo que dependências externas como Ollama, ChromaDB e SQL Server estão acessíveis e funcionais.
2. **Testes Utilitários e Pipeline de Retrieval:** Validação da lógica interna de ranking, deduplicação e construção estruturada do contexto.
3. **Testes de Integração de Ponta a Ponta:** Monitorização da pipeline RAG completa, desde a pergunta inicial em linguagem natural até à entrega final da resposta.
4. **Validação Funcional:** Execução de simulações com cenários reais e estudos de caso focados no domínio de dispositivos médicos.

O projeto inclui o pytest como framework de testes (listado em requirements.txt) para automação futura. No entanto, as validações principais durante o desenvolvimento foram executadas por via de testes manuais e de debug através de scripts interactivos, permitindo uma análise rápida de comportamentos e reações a alterações de código.

8.2 Testes de Componentes Isolados

A primeira categoria de testes garante a disponibilidade e o correto funcionamento isolado de cada componente do ecossistema:

- **Validação do Motor LLM:** O script `test_ollama_local.py` carrega as configurações do ficheiro `.env`, expõe os modelos configurados na consola para auditoria e gera um embedding para um texto padrão (ex: *“Teste de embedding para BridgeMedAI”*), validando

se a dimensionalidade corresponde a 384 ou 768 posições. Adicionalmente, submete um teste de chat ao Ollama instruindo-o a responder estritamente com a palavra “OK”, aferindo a capacidade de seguir diretivas de formatação.

- **Portabilidade do Vector Store:** Os scripts `test_chroma.py`, `test_chroma_min.py` e `test_chroma_windows.py` validam de forma multiplataforma (Linux e Windows) a obtenção da coleção regulatória, imprimindo o volume de documentos indexados e realizando um preview dos registos.
- **Validação de Regras Ingeridas:** O utilitário `debug_chroma_rules.py` extrai as fontes categorizadas como “rule” do ChromaDB e expõe os seus metadados (citação, documento, secção, páginas). Adicionalmente, corre consultas focadas como “Regra 1 dispositivos não invasivos MDR Anexo VIII” e valida se as distâncias de similaridade do cosseno retornam scores elevados para os fragmentos corretos.

8.3 Testes da Pipeline RAG Completa

O script `debug_chatbot_rag.py` efectua testes manuais de todo o fluxo de processamento. Ao receber uma pergunta via linha de comandos, o utilitário expõe na consola todas as fases de transição intermédia:

- a) A pergunta original introduzida pelo utilizador;
- b) A intenção calculada pela função `analyze_question` (ex: `classification_risk`);
- c) Os documentos-alvo priorizados (MDR, AI Act) e o backend de busca ativo;
- d) O inventário exato de fontes recuperadas (metadados, labels e scores ajustados);
- e) A resposta final estruturada entregue pelo modelo de linguagem.

Este fluxo foi validado manualmente para um conjunto alargado de perguntas padrão de conformidade (ex: diferenças entre avaliação clínica e PMCF, obrigações do Artigo 83 do MDR, e exigências de documentação técnica para Classe IIb).

8.4 Validação de Geração de Documentos

A validação funcional da automação de documentos estruturados (como o plano PMCF) foi simulada recorrendo a um caso de estudo prático: um **termómetro de infravermelhos com algoritmo de IA para diagnóstico de febre**, destinado a hospitais.

- **Análise do Perfil:** A descrição foi enviada ao endpoint `/regulatory/analyze-device`, devolvendo a classificação como Classe IIa (MDR Anexo VIII Regra 10) e IA de risco

elevado (AI Act Artigo 6), mapeando as normas ISO 13485, ISO 14971, IEC 62304 e IEC 62366.

- **Triagem de Campos:** O endpoint `/regulatory/missing-fields` filtrou os metadados em falta, agrupando as lacunas por blocos lógicos e isolando os campos que requeriam intervenção técnica humana obrigatória.
- **Inspeção do Artefacto:** O plano PMCF foi exportado via `/regulatory/generate-pmcf` em formato `.docx`. A validação técnica do ficheiro confirmou a integridade da estrutura, a inclusão correta dos dados automáticos e a presença de marcadores visuais explícitos (“*Preencher manualmente*”) nas secções de competência exclusiva humana.

8.5 Testes de Matriz de Rastreabilidade

A integridade da matriz de rastreabilidade (RTM) foi testada pontualmente nas três frentes operacionais do sistema:

- **Interações de Chat:** Confirmação do registo imediato de dados de auditoria (ID de trace, ID de utilizador, intenção, referências de contexto utilizadas e citações de saída).
- **Fluxo Regulatório:** Validação do histórico de captura das características técnicas do dispositivo submetido, classe deduzida e obrigações aplicadas.
- **Gestão Documental:** Monitorização dos logs de exportação, registando o caminho físico do ficheiro, o identificador único e a distribuição percentual entre campos automáticos e manuais.

8.6 Testes de Validação de Dados e Segurança

A integridade da plataforma foi submetida a testes de segurança e validação de fronteira:

Tabela 2: Testes de validação de dados e segurança

Componente de Segurança			Vulnerabilidade Testada	Comportamento do Sistema
Autenticação	de	Pas- sword	Credenciais fracas ou curtas	Rejeição imediata com erro claro.
Controlo	de	Sessão	Tokens adulterados ou expirados	Bloqueio e exigência de novo login.
Modelo	de	Papéis	Privilégios cruzados (Customer vs Admin)	Erro 403 HTTP de acesso negado.
Upload de Evidências			Ficheiros nocivos ou acima de 10 MB	Bloqueio por extensão e tamanho.
Campos	do	Plano	Formatos inválidos (Datas, Emails)	Validação Pydantic impede escrita.
PMCF				

8.7 Validação com Caso de Estudo Real

O sistema foi sujeito a uma simulação avançada mimetizando um **software médico isolado (standalone) de análise de imagens de ressonância magnética (RM) com IA para detecção de tumores cerebrais**. O perfil define o produto como Classe III segundo o MDR e sistema de IA de risco elevado segundo o AI Act. A pipeline RAG foi testada com uma sequência cronológica de questões:

1. *“Que regulamentos aplicam-se a um software de RM com IA para diagnóstico de tumores?”* → O sistema recuperou e recomendou o enquadramento do MDR Artigo 2 e Anexo VIII (Classe III) combinado com o Artigo 6 do AI Act e normas harmonizadas.
2. *“Quais são os requisitos gerais de segurança para este dispositivo?”* → Retornou os fragmentos de segurança essencial e desempenho do Anexo I (GSPR) do MDR, focando design baseado em risco.
3. *“Como preciso de validar a funcionalidade do algoritmo de IA?”* → Devolveu os requisitos de ciclo de vida de software da IEC 62304 e transparência do Artigo 13 do AI Act.
4. *“Que documentação técnica precisa ser incluída no dossier regulatório?”* → Respondeu com o mapeamento completo do Anexo II do MDR (especificações, arquivos de rastreabilidade, protocolos de teste e ficheiro de risco).

O plano PMCF gerado para este estudo de caso preencheu de forma acurada os dados demográficos e de finalidade previstos, isolando com sucesso as áreas de parecer clínico e rácio de benefício-risco para validação humana.

8.8 Limitações Identificadas e Lições Aprendidas

A fase de testes e validação permitiu catalogar oportunidades de melhoria técnica e limitações operacionais da versão atual da solução:

- **Volume Documental Restrito:** A base de dados e o vector store encontram-se povoados com o articulado core do MDR, AI Act e normas base. Cenários reais podem exigir a ingestão de diretrizes adicionais do MDCG ou regulamentos regionais específicos, evidenciando a necessidade de expansão da biblioteca indexada.
- **Qualidade de Extração de PDFs:** O motor de ingestão assenta na premissa de ficheiros PDF com texto limpo nativo. Documentos regulatórios digitalizados como imagem não são processados corretamente pela biblioteca PyMuPDF, sendo indispensável a introdução futura de uma camada OCR (Optical Character Recognition).

- **Dimensionalidade de Embeddings:** Os vetores fixos de 384 ou 768 dimensões podem revelar-se limitados para capturar variações semânticas de termos médicos extremamente densos ou obscuros (ex: nichos de implantes cardíacos), sugerindo o refinamento e afinação futura de modelos de embeddings específicos do domínio de saúde biomédica.

8.9 Validação de Performance e Escalabilidade

A monitorização informal da infraestrutura local registou tempos de resposta aceitáveis para interações em ambiente académico: a latência média de processamento de consultas RAG no chat situa-se entre 1 a 3 segundos; a compilação e exportação de rascunhos em formato Word consome aproximadamente 5 segundos; a triagem de enquadramento regulatório cumpre-se entre 10 a 20 segundos.

O ChromaDB demonstrou estabilidade de indexação. Embora o sistema esteja dimensionado para dezenas ou centenas de utilizadores simultâneos, uma expansão industrial exigirá a transição para arquiteturas de vetores distribuídas e a introdução de camadas de caching, melhorias fora do âmbito do projeto de final de curso.

8.10 Processo de Validação Contínua

A plataforma foi dotada de mecanismos de melhoria contínua baseados no registo imutável da RTM. Os especialistas regulatórios humanos podem auditar as respostas geradas pela pipeline RAG e catalogar a sua conformidade técnica através de três etiquetas de estado: OK, Parcialmente Correcta ou Não Conforme. Este fluxo de comentários e classificação fornece os dados e as métricas necessárias para alimentar os ciclos seguintes de afinação de prompts e reestruturação de contextos.

9 Desafios Técnicos Encontrados e Resoluções

O desenvolvimento do BridgeMedAI enfrentou múltiplos desafios técnicos complexos resultantes da intersecção de três domínios desafiantes: inteligência artificial, engenharia de software de backend, e requisitos regulatórios estritos. Cada desafio exigiu soluções criativas e iterativas para garantir que o sistema final é confiável, preciso e auditável.

9.1 Mitigação de Alucinações em Modelos de Linguagem

O desafio mais crítico encontrado foi a tendência dos modelos de linguagem para gerar respostas aparentemente plausíveis mas factualmente incorrectas ou não fundamentadas, fenómeno conhecido como alucinação. Em contexto regulatório, uma alucinação pode ter consequências graves — uma resposta incorreta sobre requisitos de conformidade pode conduzir uma organização a tomar decisões de compliance erradas que violam regulamentos.

Os modelos de linguagem genéricos como GPT têm uma tendência forte para desenhar na sua base de conhecimento de treino e gerar informação plausível mesmo quando não têm contexto específico para uma pergunta. Por exemplo, se perguntado “Qual é o número do artigo do MDR sobre obrigações do fabricante?”, um modelo genérico pode confiantemente responder “Artigo 10” quando, de facto, artigos relevantes podem ser 10, 13, 15, 29 e outros dependendo do contexto. Sem acesso ao documento real, o modelo simplesmente adivinhou.

A solução implementada foi o Retrieval-Augmented Generation (RAG), que força o modelo a responder apenas baseado em contexto recuperado de fontes verificadas. Em vez de permitir que o modelo desenhe na sua base de conhecimento, o sistema recupera primeiro fragmentos dos documentos regulatórios reais, e depois injeta estes fragmentos no prompt antes de solicitar resposta ao modelo. Isto limita o modelo a trabalhar apenas com informação verificável.

Além disso, o sistema implementou instruções explícitas no prompt que proíbem alucinações. O system prompt base contém regras como “Não inventes artigos, anexos ou obrigações que não estejam no contexto”, “Nunca crie novos regulamentos, novos números de regulamento, nem placeholders como XXX ou YYY”, e “Se o contexto não for suficiente para responder com confiança, diz claramente isso”. Estas instruções são reforçadas consistentemente durante a fase de *prompt engineering*.

O sistema também implementa o *post-processing* de respostas para eliminar placeholders e expressões genéricas que podem indicar alucinação. Se a resposta contém expressões como “A confirmar”, “Preencher manualmente”, ou caracteres como XXX ou YYY que foram deliberadamente deixados no prompt para serem preenchidos pelo modelo, estas são

sinalizadas como possíveis alucinações e a resposta é rejeitada ou o utilizador é alertado.

Um desafio adicional foi descoberto durante testes: mesmo com RAG implementado, os modelos às vezes extrapolam além das fontes fornecidas. Por exemplo, recebendo contexto sobre “Regra 1 para dispositivos não invasivos”, o modelo pode gerar conclusões sobre “Regra 1 também cobre dispositivos semi-invasivos” se essas afirmações não existem nas fontes. A solução foi implementar validação de citações — o sistema valida que cada afirmação na resposta tem uma citação correspondente nas fontes fornecidas. Se uma afirmação não pode ser ligada a uma fonte, é sinalizada como potencial alucinação.

9.2 Qualidade de Retrieval Semântico com Embeddings

Um desafio significativo foi garantir que o retrieval semântico via embeddings recupera realmente fragmentos relevantes. A busca semântica baseada em embeddings depende de que o espaço vectorial capture correctamente o significado semântico do texto. Se o embedding de “Qual é a classificação de risco de um termómetro com IA?” é muito diferente do embedding de “Classe de um dispositivo com algoritmo”, o sistema falha em recuperar fragmentos relevantes.

O problema é agravado pelo facto de que documentos regulatórios usam vocabulário muito específico e formalizado. Um fragmento sobre “termómetro infravermelhos destinado a diagnóstico clínico de febre” é semanticamente similar a “dispositivo ativo de medição de temperatura para triagem”, mas se o modelo de embeddings não foi treinado em documentos regulatórios específicos, a similaridade pode ser pobre.

A solução implementada foi de dupla abordagem (*twofold*). Primeiro, o sistema constrói múltiplas variantes semânticas de cada pergunta através da função `build_query_variants`. Em vez de confiar numa única embedding de pergunta, o sistema gera múltiplas reformulações semânticas e recupera para cada uma. Isto aumenta a probabilidade de que pelo menos uma variante recupere fragmentos relevantes. Segundo, o sistema implementa ajustes heurísticos de scores baseado em regras específicas do domínio regulatório.

O ajuste heurístico é crítico. Por exemplo, o sistema implementa uma regra que se a pergunta menciona IA ou algoritmos, fragmentos do AI Act recebem um *boost* de score. Se a pergunta é sobre software médico, fragmentos de IEC 62304 recebem *boost*. Esta abordagem de *ranked retrieval* com *domain-specific heuristics* melhora significativamente a qualidade dos resultados.

Outro desafio foi a deduplicação de fragmentos. O mesmo artigo ou secção do regulamento pode aparecer em múltiplos chunks diferentes (por exemplo, em diferentes níveis de granularidade). Sem deduplicação, o contexto final pode conter o mesmo requisito repetido múltiplas vezes com ligeiras variações. A solução foi implementar deduplicação baseado

no campo “citation_label” — fragmentos com a mesma citação (ex: “MDR Artigo 10”) são consolidados, mantendo apenas o fragmento com score mais elevado.

9.3 Processamento de Documentos Regulatórios em PDF

Um desafio técnico fundamental foi extrair texto de documentos regulatórios em formato PDF. O MDR e AI Act foram publicados pela UE como ficheiros PDF, e a extração confiável de texto estruturado a partir destes documentos foi crucial para o sucesso do projecto.

O desafio principal é que os PDFs podem armazenar texto de múltiplas formas: como texto puro (onde o PDF contém caracteres e fontes), como imagens digitalizadas (onde o conteúdo é uma fotografia do documento), ou como mistura de ambas. Extractores de texto simples falham em documentos digitalizados. O projecto utilizou PyMuPDF (biblioteca `fitz`) que consegue extrair texto de PDFs com texto puro, mas ainda pode falhar com documentos que contêm muitas imagens ou estruturas muito complexas.

A solução foi assumir que os documentos regulatórios fornecidos estão em formato de texto puro (not digitalizados), o que é verdade para a maioria de documentos oficiais publicados digitalmente. No entanto, isto é documentado como uma limitação — se um cliente fornece uma versão digitalizada de um regulamento, o sistema não conseguirá processar correctamente.

Um segundo desafio foi preservar a estrutura dos documentos durante a extração. O MDR tem uma hierarquia bem definida: capítulos contêm artigos, artigos têm parágrafos numerados, alguns têm alíneas sub-numeradas. Perder esta estrutura torna difícil identificar e citar correctamente secções. A solução foi implementar heurísticas para detectar a hierarquia durante o *parsing* — por exemplo, “Article 10” é detectado como início de novo artigo, “10.1” é detectado como parágrafo do artigo 10, “10.1(a)” é detectado como alínea.

Um terceiro desafio foi a normalização de texto. Os PDFs às vezes contêm variações em codificação de caracteres, espaços em branco inconsistentes, quebras de linha em locais inesperados, e acentos representados de diferentes formas. A solução implementada foi aplicar normalização Unicode (decomposição NFKD) e limpeza de espaço em branco após extração de cada bloco de texto.

9.4 Determinação de Intenção Regulatória Correcta

Um desafio significativo foi classificar correctamente a intenção regulatória subjacente de uma pergunta. A mesma pergunta pode ser interpretada de múltiplas formas. Por exemplo, “Termómetro com IA — qual classe?” pode ser interpretado como pergunta de classificação

de risco (`classification_risk`), pergunta de documentação (`documentation` — qual documentação é exigida para esta classe), ou pergunta de conformidade (`conformity_procedure` — qual procedimento para obter conformidade para esta classe).

A classificação correcta de intenção é crítica porque o sistema adapta o contexto recuperado e o prompt enviado ao modelo baseado na intenção detectada. Se a intenção é mal-identificada, o contexto pode estar incorrecto mesmo que o retrieval semântico em si funcione bem.

O desafio é que a intenção é frequentemente ambígua até contexto adicional ser considerado. Por exemplo, “O que é o PMCF?” por si só é ambíguo — pode ser pergunta sobre o que é PMCF (`device_qualification`), ou pergunta sobre o conteúdo de um plano PMCF (`pmcf_plan`), ou pergunta sobre quando o PMCF é exigido (`regulatory_scope`).

A solução implementada foi usar um sistema de prioridades nas palavras-chave. O sistema detecta termos-chave que indicam intenção e ordena intenções por prioridade. Por exemplo, `DOCUMENT_GENERATION_TERMS` tem prioridade alta — se a pergunta contém “gera o documento”, “faz o PMCF”, ou “cria template”, a intenção é imediatamente classificada como `document_generation` independente de outras palavras-chave presentes. Isto permite que o sistema lide com perguntas compostas.

O sistema também implementa análise de contexto histórico. Se o utilizador anteriormente perguntou “Qual é a classe MDR?” e agora pergunta “Qual documentação?”, o sistema infere que a pergunta actual é contexto de continuação da anterior, então a intenção pode ser `documentation` para aquela classe específica.

9.5 Prompting Adaptativo para Diferentes Intenções

Um desafio técnico importante foi descobrir que um único prompt genérico não consegue fazer o modelo comportar-se bem para todos os tipos de perguntas regulatórias. Respostas sobre classificação de risco têm características diferentes de respostas sobre documentação requerida, que têm características diferentes de respostas sobre obrigações do fabricante.

Por exemplo, para `classification_risk`, o prompt precisa explicar que o modelo deve considerar a Regra 1 para dispositivos simples não invasivos, mas a Regra 10 para dispositivos digitais activos, mas nem sempre deve concluir Classe III imediatamente para software de diagnóstico. Sem estas instruções específicas, o modelo frequentemente generaliza incorrectamente.

Para `manufacturer_obligations`, o prompt precisa ser explícito de que obrigações de organismos notificados não devem ser listadas como obrigações do fabricante. Sem esta instrução, o modelo inclui confusamente obrigações de ambos.

A solução foi implementar caminhos de *prompting* adaptativo através do dicionário `SYSTEM_PROMPT_BY_INTENT`. Para cada intenção detectada, o sistema constrói um prompt customizado que inclui instruções específicas para aquela intenção. O prompt base contém regras globais, e então um prompt específico da intenção é concatenado com instruções especializadas.

Este *prompting* adaptativo requer manutenção cuidadosa. Cada intenção tem um prompt cuidadosamente calibrado baseado em observações de como o modelo se comporta. Por exemplo, o prompt para `classification_risk` includes vários exemplos do tipo “Se perguntarem sobre termómetro simples não invasivo sem indicação de que é digital/ativo, responde Classe provável Classe I”. Sem estes exemplos, o modelo frequentemente chega a conclusões erradas.

9.6 Rastreabilidade Completa sem Impactar Performance

Um desafio importante foi implementar rastreabilidade completa (cada pergunta, cada retrieval, cada resposta registrada) sem que a sobrecarga de *logging* impacte significativamente a performance. O *logging* completo é crítico para auditoria regulatória, mas o *logging* síncrono em cada operação seria muito lento.

O desafio específico é que o sistema precisa registrar: a pergunta original, a intenção detectada, os documentos-alvo, cada fragmento recuperado com score, cada fragmento final incluído no contexto, a resposta gerada completa, o utilizador que fez a pergunta e o *timestamp* preciso.

Fazer todas estas operações em SQL Server de forma síncrona durante a resposta seria muito lento. A solução implementada foi fazer a maioria do *logging* síncrono (para garantir que está completo), mas de forma otimizada. O sistema agrupa múltiplas inserções em SQL Server numa única operação *batch*, e utiliza índices de base de dados para garantir que as queries de leitura da matriz de rastreabilidade são rápidas.

O sistema também implementa um cache em memória para queries recentes da matriz de rastreabilidade, de modo que quando um utilizador visualiza o histórico das suas interações, não há query à base de dados — é servido diretamente do cache.

9.7 Gestão de Estado em Conversas Longas

Um desafio descoberto durante testes foi que conversas longas (muitas perguntas e respostas do utilizador) podem resultar em contexto crescente. Se cada pergunta inclui o histórico completo de conversas anterior, eventualmente o histórico torna-se tão longo que não cabe num prompt de modelo.

Além disso, o histórico antigo pode interferir com a atual pergunta. Por exemplo, se o utilizador perguntou há dez interações “Que dispositivos de Classe I conheces?” e depois pergunta “Qual é a documentação exigida?”, o modelo pode ficar confuso sobre qual dispositivo específico o utilizador está referindo.

A solução implementada foi a aplicação de uma estratégia de janela deslizante (*sliding window*) de histórico. O sistema mantém apenas as últimas N interações (por exemplo, últimas 5 conversas) no contexto enviado ao modelo. Interações mais antigas não são esquecidas completamente — são registadas na matriz de rastreabilidade — mas não são incluídas no prompt actual.

O sistema também implementa uma função de memória de contexto (*context memory*) que extrai informação relevante de conversas anteriores sem incluir o texto integral (*verbatim*). Por exemplo, se o utilizador descreveu um dispositivo específico há múltiplas interações, o sistema extrai e armazena a descrição do dispositivo num perfil de utilizador, e em conversas futuras inclui apenas este perfil extraído em vez de toda a conversa histórica.

9.8 Compatibilidade e Portabilidade de Componentes

Um desafio importante foi garantir compatibilidade entre o Ollama (que executa localmente) e o ChromaDB (que pode executar em modo local ou remoto) através de diferentes plataformas (Linux, Windows, macOS). Isto é particularmente desafiante porque o Ollama e o ChromaDB têm diferentes requisitos de ambiente.

Por exemplo, o Ollama em Windows pode ser lento sem uma GPU adequada, enquanto em Linux com GPU é muito mais rápido. O ChromaDB em modo HTTP requer um servidor separado; em modo persistente requer acesso direto ao disco local. Diferentes combinações podem funcionar bem em alguns ambientes mas falhar noutros.

A solução passou por implementar múltiplos scripts de teste para diferentes plataformas (`test_ollama_local.py`, `test_chroma.py`, `test_chroma_windows.py`) que permitem aos operadores diagnosticar problemas de compatibilidade rapidamente. O sistema também implementa mecanismos de recuo (*fallbacks*) — se o Ollama não estiver respondendo rápido, o sistema notifica o utilizador em vez de bloquear a aplicação.

O sistema também implementa a configuração via ficheiro `.env` que permite aos operadores customizar os *endpoints* do Ollama e do ChromaDB sem alterar o código-fonte. Isto torna o sistema inteiramente portátil para diferentes ambientes de implementação (*deployment*).

9.9 Validação de Campos Estruturados em Templates

Um desafio fatal foi implementar a validação de dados para os campos estruturados do template PMCF. Cada campo tem um tipo específico (texto, data, número, email, etc.) e o sistema precisa validar que o preenchimento automático é correcto e que o preenchimento manual segue as regras de negócio.

Por exemplo, o campo `pmcf_plan_date` deve estar obrigatoriamente no formato AAAA-MM-DD. Se o sistema preenchesse automaticamente com uma data inválida como “2026-13-01” (mês 13 não existe), isto consistiria num erro regulatório grave. Se o utilizador preencher manualmente com “28-05-2026”, isto constitui o formato europeu que precisa de ser convertido.

A solução foi implementar validadores Pydantic para cada campo estruturado, com mensagens de erro específicas. Para campos de data, o sistema tenta múltiplos formatos conhecidos e rejeita a submissão se nenhum funcionar. Para campos de email, utiliza a validação da biblioteca `email-validator`. Para campos de enumeração (*enum*, ex: o status apenas pode ser “pending”, “approved”, ou “rejected”), o sistema valida que apenas valores permitidos são aceites.

9.10 Consistência de Citações nas Respostas

Um desafio técnico significativo foi garantir que as respostas geradas pelo modelo citam correctamente as fontes utilizadas. O modelo recebe o contexto com fontes claramente marcadas com rótulos (*labels*) de citação, mas ocasionalmente referia as fontes incorrectamente, por exemplo dizendo “conforme FONTE 1” em vez de “conforme MDR Artigo 10”.

Este desafio é importante porque citações incorrectas prejudicam a rastreabilidade — se a resposta cita “FONTE 1” mas o utilizador não consegue depois identificar qual o artigo específico que foi referido, a utilidade da resposta em sede de auditoria é severamente reduzida.

A solução consistiu num desenho de prompts muito claro que reforça o uso das etiquetas de citação correctas. O prompt diz explicitamente: “Usa sempre o valor do campo ‘Citação:’ da fonte, por exemplo ‘MDR Artigo 10’ ou ‘AI_ACT Artigo 6’. Não uses ‘FONTE 1’, ‘FONTE 2’ ou semelhante.” O sistema também implementa uma camada de pós-processamento (*post-processing*) textual que detecta citações incorrectas e as corrige ou sinaliza automaticamente.

9.11 Gestão de Escala e Performance

Um desafio importante durante o desenvolvimento foi garantir que o sistema mantém uma performance aceitável mesmo perante múltiplos utilizadores simultâneos e um grande volume de dados. O ChromaDB precisa de responder com baixa latência mesmo com centenas de milhares de chunks indexados, e as queries ao SQL Server devem manter-se rápidas mesmo com milhões de registos de rastreabilidade acumulados.

A solução passou por implementar índices adequados no SQL Server (índices estruturados nos campos `user_id`, `conversation_id` e `created_at`), complementados pela utilização de caches em memória para as queries mais frequentes. O sistema também implementa paginação nativa para todas as listagens de dados (ex: a fila de submissões apresentada aos especialistas), evitando carregar grandes volumes de registos desnecessariamente para a memória volátil.

10 Exemplo Prático

O exemplo prático apresenta a aplicação do BridgeMedAI a um caso representativo de um dispositivo médico com componente inteligente. O fluxo inclui o registo do dispositivo, a análise automática de requisitos, a geração da matriz de rastreabilidade e a apresentação dos resultados num painel de apoio à decisão.

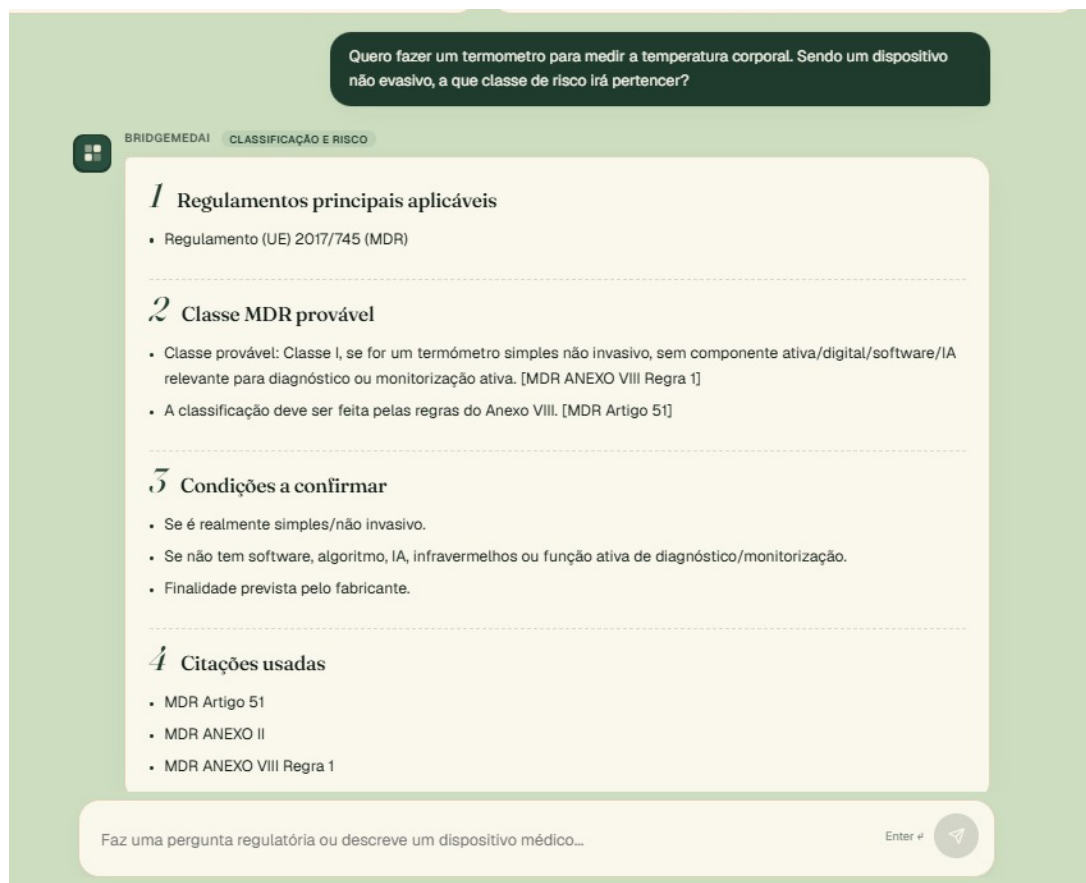


Figura 3: Interface de Chat do Utilizador (BridgeMedAI) — Apresenta a interface principal de conversação do utilizador com o assistente, demonstrando a submissão de uma dúvida regulatória e a resposta estruturada do sistema.

Quero fazer um termómetro para medir a temperatura corporal. Sendo um dispositivo não invasivo, a que classe de

CHAT - 2025-06-04 19:20

PARECE CONSISTENTE

FEEDBACK POR DAR

PRÉ-VALIDAÇÃO AUTOMÁTICA

Parece consistente - Caso: Termómetro simples não invasivo - Similaridade: 57%

A resposta parece alinhada com o caso de referência. Ainda assim, pode enviar ao especialista para validação formal.

✓ Classe MDR

Esperado: I

Detetado: I

✓ Regra/citação MDR usada

Esperado: MDR ANEXO VIII Regra 1

Probabilidade calculada em momento finalizar esta resposta

A TUA PERGUNTA

Quero fazer um termómetro para medir a temperatura corporal. Sendo um dispositivo não invasivo, a que classe de risco irá pertencer?

RESPOSTA DO ASSISTANT

1. Regulamentos principais aplicáveis

- Regulamento (UE) 2017/745 (MDR)

2. Classe MDR provável

- Classe provável: Classe I, se for um termómetro simples não invasivo, sem componente activa/digital/software/IA relevante para diagnóstico ou monitorização activa. [MDR ANEXO VIII Regra 1]

- A classificação deve ser feita pelas regras do Anexo VIII. [MDR Artigo 51]

3. Condições a confirmar

- Se é realmente simples/não invasivo.

- Se não tem software, algoritmo, IA, infravermelhos ou função activa de diagnóstico/monitorização.

- Finalidade prevista pelo fabricante.

A TUA AVALIAÇÃO

NOTAS (OPCIONAL)

Passou em todos os testes da matriz automática. Verifica se está de facto tudo bem.

✓ ÚTIL

PARCIALMENTE ÚTIL

X NÃO FOI ÚTIL

ENVIAR PARA ESPECIALISTA

Figura 4: Interface de Pré-Validação Automática e Avaliação — Ilustra o painel com o resultado da pré-validação automática (consistência e similaridade) e a secção para o utilizador registar notas de feedback.

ESPECIALISTA - ANÁLISE

Pedidos de *revisão*

Entradas que os utilizadores enviaram explicitamente para revisão especializada.

RECARREGAR

5 ENTRADA(S) A AGUARDAR REVISÃO

Quero fazer um termómetro simples, sendo um dispositivo não invasivo, a que classe de risco irá pertencer?

CHAT - 2025-06-03 13:42

PEDIDO PELO UTILIZADOR

POR REVER

CONTEÚDO

PERGUNTA

Quero fazer um termómetro simples, sendo um dispositivo não invasivo, a que classe de risco irá pertencer?

RESPOSTA

1. Regulamentos principais aplicáveis

- Regulamento (UE) 2017/745 (MDR)

2. Classe MDR provável

- Classe provável: Classe I, se for um termómetro simples não invasivo, sem componente activa/digital/software/IA relevante para diagnóstico ou monitorização activa. [MDR ANEXO VIII Regra 1]

- A classificação deve ser feita pelas regras do Anexo VIII. [MDR Artigo 51]

3. Condições a confirmar

- Se é realmente simples/não invasivo.

- Se não tem software, algoritmo, IA, infravermelhos ou função activa de diagnóstico/monitorização.

REVISÃO

RESULTADO

OK

PARCIAL

NOK

SEVERIDADE

TIPO DE ERRO

NOTAS (O QUE MELHORAR, OBSERVAÇÕES)

Neste caso está correto, no entanto se verificarmos que se irá tratar de um dispositivo invasivo, este já terá pelo menos Classe de risco IIa.

✓ GUARDAR REVISÃO

MARCAR COMO OK

MARCAR COMO PARCIAL

MARCAR COMO NOK

Figura 5: Painel de Gestão de Pedidos de Revisão do Especialista — Mostra a perspetiva interna do especialista, permitindo analisar perguntas pendentes, classificar erros e submeter observações de correção.

42

A TUA PERGUNTA

Quero fazer um termómetro simples, sendo um dispositivo não invasivo, a que classe de risco irá pertencer?

RESPOSTA DO ASSISTANT

1. Regulamentos principais aplicáveis
- Regulamento (UE) 2017/745 (MDR)

2. Classe MDR provável
- Classe provável: Classe I, se for um termómetro simples não invasivo, sem componente ativa/digital/software/IA relevante para diagnóstico ou monitorização ativa. [MDR ANEXO VIII Regra 1]
- A classificação deve ser feita pelas regras do Anexo VIII. [MDR Artigo 51]

3. Condições a confirmar
- Se é realmente simples/não invasivo.
- Se não tem software, algoritmo, IA, infravermelhos ou função ativa de diagnóstico/monitorização.
- Finalidade prevista pelo fabricante.

REVISÃO DO ESPECIALISTA

VALIDADO

Neste caso está correto; no entanto, se verificarmos que se irá tratar de um dispositivo invasivo, este já terá pelo menos Classe de risco IIa.

Revisto em 2828-06-04 10:33

A TUA AVALIAÇÃO

NOTAS (OPCIONAL)

Ex: 'A resposta foi útil mas faltou citar o artigo X' ou 'Não percebi a classificação que sugeriu'

✓ ÚTIL

PARCIALMENTE ÚTIL

X NÃO FOI ÚTIL

ENVIADO PARA ESPECIALISTA

Figura 6: Histórico de Revisão e Feedback do Especialista — Detalha a interface de acompanhamento do utilizador, exibindo o parecer técnico e o estado de validação emitido pelo especialista humano.

11 Resultados

A implementação do framework BridgeMedAI permite demonstrar a viabilidade de uma abordagem integrada para apoio à conformidade regulatória de dispositivos médicos com e sem componentes de Inteligência Artificial. A solução desenvolvida procurou responder aos principais desafios identificados ao longo do projeto, nomeadamente a fragmentação documental, a redundância de requisitos regulamentares e a dificuldade em manter rastreabilidade consistente entre requisitos, evidências e documentação técnica.

A validação preliminar do sistema foi realizada através da aplicação do framework a um caso de estudo representativo de um dispositivo médico com componente de IA, permitindo avaliar o comportamento da plataforma em cenários típicos de preparação documental e apoio à auditoria. Os resultados obtidos evidenciaram melhorias em diferentes dimensões do processo de conformidade:

- Estruturação centralizada dos requisitos regulamentares e normativos aplicáveis, reduzindo a dispersão de informação entre múltiplas fontes;
- Criação automática de ligações entre requisitos, evidências e atividades de validação, facilitando a geração de matrizes de rastreabilidade;
- Apoio à elaboração documental através de templates normalizados e geração assistida por LLMs;
- Identificação precoce de lacunas documentais e requisitos pendentes;
- Maior transparência e auditabilidade do processo de compliance.

Durante os testes realizados, verificou-se que a utilização de mecanismos de Retrieval-Augmented Generation (RAG) contribuiu para reduzir respostas não fundamentadas por parte do assistente baseado em IA, garantindo que os conteúdos gerados fossem contextualizados com base em documentação regulatória previamente indexada.

Adicionalmente, a introdução de workflows de validação humana permitiu assegurar que todas as respostas e documentos produtos pelo sistema permanecessem sujeitos a revisão especializada, mitigando riscos associados à utilização de modelos de linguagem em contextos regulatórios críticos.

Do ponto de vista arquitetural, a separação modular entre frontend, backend, serviços de IA, armazenamento relacional e vector store revelou-se adequada para suportar escalabilidade, rastreabilidade e futura evolução funcional da plataforma.

Apesar dos resultados positivos obtidos, o projeto apresenta ainda algumas limitações. A validação foi realizada num cenário controlado e com um conjunto reduzido de documentos regulamentares, sendo necessária uma futura expansão para contextos reais de certificação

e auditoria. Adicionalmente, a eficácia dos mecanismos de IA depende diretamente da qualidade dos documentos indexados e das estratégias de recuperação semântica utilizadas.

12 Trabalho Futuro

O desenvolvimento do BridgeMedAI estabeleceu uma base sólida para a convergência entre regulação de dispositivos médicos e automação inteligente. No entanto, foram identificadas diversas frentes de evolução técnica e de experiência de utilizador que constituem oportunidades para trabalho futuro.

12.1 Streaming das Respostas

Parecer: *[Altamente Recomendado]*

Esta é uma melhoria com retorno de investimento operacional muito elevado. A latência percebida é um problema crítico em aplicações interactivas — mesmo que o sistema leve cerca de 3 segundos a gerar uma resposta completa, se o utilizador vir a resposta a ser escrita progressivamente no ecrã, a experiência de utilização torna-se significativamente mais fluida e interactiva.

Do ponto de vista da implementação técnica, as ferramentas `FastAPI` e `Pydantic` já suportam transmissão nativa através da classe `StreamingResponse`. Basicamente, em vez de gerar a resposta completa na memória e depois devolver a totalidade dos dados numa única invocação, o modelo linguístico gera a resposta em blocos (*chunks* atómicos de texto, como palavra a palavra ou frase a frase) e cada bloco é enviado para o cliente em tempo real. No frontend, é realizado o processamento deste fluxo contínuo de texto, que surge progressivamente na interface do utilizador.

Esta alteração resulta numa experiência de utilizador muito mais moderna, responsiva e alinhada com as aplicações comerciais contemporâneas. Os utilizadores passam a perceber o ecossistema como mais rápido, mesmo que o tempo computacional total de execução seja idêntico, mitigando a ansiedade de espera. O único desafio menor reside na necessidade de sincronização rigorosa com o processamento de fontes: a pipeline não pode iniciar a escrita antes de a recuperação semântica e estruturação do contexto estarem inteiramente concluídas. Apresenta uma prioridade alta por ser uma alteração de implementação rápida com grande impacto direto no utilizador.

12.2 Indicador Visual Durante o Retrieval

Parecer: *[Recomendado, Complementa Bem o Streaming]*

A introdução de um indicador visual intermédio é crucial para a transparência do sistema, permitindo que o utilizador compreenda que a plataforma está a executar tarefas complexas em background antes de o texto começar a ser transmitido. Tecnicamente, traduz-se na

inclusão de um componente visual de carregamento (*loading indicator*) ou de uma mensagem dinâmica informativa (ex: “*A procurar nas fontes relevantes...*”) que é renderizada assim que o utilizador submete a consulta e que se oculta automaticamente no momento em que o *streaming* da resposta se inicia.

O benefício adicional desta abordagem é pedagógico: permite ao operador compreender visualmente a pipeline interna do sistema (*retrieval* → geração → resposta), fomentando a confiança no ecossistema e promovendo a literacia tecnológica sobre o funcionamento do padrão RAG. Como sugestão de refinamento técnico, este indicador poderá apresentar metadados em tempo real sobre a busca (ex: “*Recuperadas X fontes normativas relevantes, a construir contexto estruturado...*”), enriquecendo o feedback de controlo fornecido ao utilizador. A sua prioridade é considerada média-alta por possuir uma implementação trivial e grande impacto na experiência de utilização.

12.3 Refinamento Contínuo dos Prompts Regulatórios

Parecer: [*Absolutamente Essencial para Longo Prazo*]

O aperfeiçoamento da engenharia de prompts representa um dos ativos de maior valor a longo prazo para o projeto. Os prompts integrados na arquitetura atual foram definidos de forma empírica durante a fase de testes e desenvolvimento, existindo ainda margem considerável para otimização sistemática, dado que a qualidade e a precisão técnica das respostas do sistema dependem de forma linear do rigor destas diretivas.

Atualmente, verifica-se estabilidade e bom desempenho na separação de prompts dedicados por classes de intenção, nas instruções negativas estritas de combate a alucinações e na inclusão de exemplos práticos no formato *few-shot learning*. Contudo, existem ainda áreas críticas que carecem de refinamento contínuo:

- **Segregação de Diplomas:** Observam-se episódios em que alguns prompts genéricos induzem o modelo a confundir e fundir obrigações do MDR com as exigências do AI Act (ex: responder sobre classificações clínicas integrando indevidamente regras de risco de algoritmos);
- **Divisão de Responsabilidades:** Detetam-se situações pontuais onde os prompts que delimitam as obrigações dos fabricantes face às competências dos organismos notificados geram ambiguidades contextuais na resposta;
- **Tratamento de Consultas Compostas:** O motor de deteção de intenções pode manifestar menor eficácia perante perguntas compostas ou que cruzem múltiplos objetivos regulatórios na mesma frase.

Para mitigar estas limitações, propõe-se o desenho de uma estratégia sistemática de refinamento baseada num pipeline estruturado de quatro etapas: primeiro, o registo permanente de respostas de baixa qualidade (*logging* automático quando o score de confiança computado for inferior aos limiares predefinidos ou sempre que um especialista humano classifique a interação como “PARCIAL” na matriz de rastreabilidade); segundo, a análise de padrões através do agrupamento das respostas insatisfatórias por intenções; terceiro, a execução de testes comparativos (*A/B Testing*) de variações de prompts num subconjunto controlado de perguntas; e, por fim, a iteração e atualização de segurança do dicionário core do sistema.

O maior desafio desta vertente assenta na necessidade de disciplina e metodologia científica, evitando alterações pontuais ad-hoc que possam degradar o comportamento do modelo noutros cenários que já se encontravam estabilizados. Recomenda-se a construção de uma suite de testes automatizada contendo perguntas de referência jurídica invariantes para homologar qualquer modificação futura nos prompts. A sua prioridade é máxima e contínua.

12.4 Fecho do Ciclo de Aprendizagem via Fine-tuning do Modelo Local

Parecer: [*Atenção / Ressalva Importante*]

O fecho do ciclo de aprendizagem através de técnicas de *fine-tuning* constitui uma evolução sofisticada, mas que exige considerável cautela na sua abordagem. O conceito foca-se em reaproveitar o conhecimento gerado pelas equipas de auditoria (ex: correções textuais manuais introduzidas pelos especialistas regulatórios quando assinalam respostas geradas como incorretas ou incompletas) para re-treinar periodicamente o modelo de linguagem local do Ollama, especializando as capacidades linguísticas nativas da plataforma ao longo do tempo.

Embora o potencial estratégico de dispor de um modelo especializado no domínio regulatório biomédico seja muito elevado, a sua implementação industrial enfrenta desafios técnicos severos:

- **Qualidade da Rotulagem de Dados (*Data labeling quality*):** A premissa de treino assume a correção absoluta do revisor humano. Se um especialista cometer um erro de interpretação e o sistema capturar esse dado para treino, o *fine-tuning* irá injetar esse erro de forma permanente nos pesos do modelo. Torna-se indispensável conceber uma arquitetura com dois níveis de validação humana em cascata antes da exportação de dados de treino;
- **Esquecimento Catastrófico (*Catastrophic forgetting*):** Ao ajustar os pesos sinápticos

com base num nicho documental muito específico, o modelo corre o risco de degradar a sua capacidade de compreensão de linguagem geral ou de esquecer diretivas regulatórias transversais. Seria obrigatório recorrer a metodologias adaptativas paramétricas como a injeção de adaptadores LoRA (*Low-Rank Adaptation*) ou a inclusão de técnicas de repetição de amostras genéricas históricas (*data replay*);

- **Viés de Distribuição:** Se a amostragem de auditoria do sistema estiver muito concentrada num determinado tipo de dispositivo (ex: muitos termómetros de febre), o modelo sofrerá uma sobre-especialização enviesada. É necessária uma estratégia ativa de balanceamento de dados;
- **Custos Computacionais:** Os processos de re-treino exigem infraestruturas de hardware robustas (GPUs de alta capacidade), cujo processamento síncrono pode degradar significativamente o desempenho geral do servidor.

Como alternativa complementar a curto e médio prazo, recomenda-se explorar primeiro a otimização dinâmica do *retrieval*, adaptando as janelas de extração semântica e os scores heurísticos com base no feedback histórico, bem como expandir o portefólio de exemplos injetados dinamicamente nos prompts via *few-shot learning*, o que é computacionalmente reversível e isento de riscos de degradação estrutural do modelo. O *fine-tuning* deverá ser relegado para uma fase secundária de maturidade do projeto, idealmente após a acumulação estável de vários anos de dados históricos consolidados.

12.5 Suporte a Vários Idiomas

Parecer: [*Muito Valioso, Mas Significativamente Complexo*]

A disponibilização da plataforma em múltiplos idiomas reveste-se de elevado interesse comercial e operacional, dado que os regulamentos centrais (MDR e AI Act) possuem aplicabilidade direta em todo o espaço económico da União Europeia. Contudo, do ponto de vista da engenharia de software e processamento de linguagem natural, esta funcionalidade acrescenta camadas severas de complexidade técnica que impossibilitam uma abordagem assente em simples tradução automática:

- i. **Indexação e Ingestão Multilíngue em Base de Dados:** Os documentos regulatórios oficiais publicados pela UE existem em todas as línguas oficiais. Para garantir o rigor e a validade jurídica das fontes de contexto recuperadas, os PDFs originais em inglês, francês ou alemão têm de ser integralmente extraídos, segmentados e indexados de forma paralela e isolada em coleções autónomas do **ChromaDB**. Confiar em traduções automáticas em tempo real para dados legais introduz riscos inaceitáveis de deturpação de termos jurídicos estritos;

- ii. **Mapeamento Semântico de Intenções por Idioma:** O utilitário backend de triagem sintática precisa de ser inteiramente reestruturado e parametrizado para cada novo idioma suportado, mapeando exaustivamente os termos-chave correspondentes e tratando as regras de prioridade concorrente de acordo com as nuances gramaticais e estilísticas de cada língua;
- iii. **Calibração e Alinhamento de Prompts:** Os prompts do sistema precisam de ser traduzidos e calibrados de forma isolada por idioma, visto que expressões imperativas de negação ou placeholders comportam-se de forma distinção dependendo da língua e do modelo linguístico local utilizado;
- iv. **Modelos de Embeddings Multilíngues:** A vector store do sistema teria de migrar de modelos monolíngues especializados para arquiteturas multilíngues consolidadas (como o modelo `multilingual-e5-large`). Embora estes modelos possuam elevada versatilidade linguística, manifestam por vezes uma perda marginal de precisão cirúrgica quando comparados com modelos otimizados nativamente para um único idioma.

Para acomodar esta evolução sem comprometer a estabilidade do sistema, propõe-se um plano de implementação faseado em três etapas distintas: a Fase 1 (Curto Prazo), focada na consolidação bidirecional em Inglês e Português, permitindo testar e estender a infraestrutura de dados para suportar múltiplos enquadramentos de indexação sem dispersão de recursos; a Fase 2 (Médio Prazo), dedicada à ingestão jurídica das coleções em Francês e Alemão, visando cobrir os principais mercados regulatórios da Europa Central; e a Fase 3 (Longo Prazo), direcionada para a expansão gradual dos restantes idiomas comunitários conforme a procura de mercado.

Arquiteturalmente, recomenda-se organizar isolamentos lógicos via ficheiros `.env` independentes por idioma de trabalho e implementar um módulo inicial de encaminhamento automático (*routing system*) capaz de identificar o idioma da consulta do utilizador e direcionar o processamento para a respetiva esteira linguística correspondente da pipeline RAG. Apresenta uma prioridade média, devendo ser atacado após a estabilização completa da versão monolíngue atual.

13 Declaração de Utilização de Inteligência Artificial

Em conformidade com as boas práticas acadêmicas e as diretrizes de integridade institucional, declara-se que foram utilizadas ferramentas de Inteligência Artificial Generativa no processo de elaboração do projeto descrito.

A assistência por IA focou-se no suporte à revisão, estruturação de tópicos técnico-regulatórios e desenvolvimento assistido de código. Importa destacar que o mapeamento conceptual do ecossistema BridgeMedAI, a modelação lógica da base de dados relacional e vetorial, a definição da arquitetura do sistema e a validação final de todas as análises regulatórias apresentadas foram revistas e validadas integralmente pelos membros deste grupo de trabalho.

14 Referências

Referências

- [1] Aboy, M., Minssen, T., & Vayena, E. (2024). Navigating the EU AI Act: implications for regulated digital medical products. *NPJ Digital Medicine*, 7(1), 237.
- [2] Arora, C., et al. (2024). Towards standards-compliant assistive technology product specifications via LLMs. *IEEE International Requirements Engineering Conference Workshops (REW)*.
- [3] Belmoukadam, O., et al. (2024). AdversLLM: A practical guide to governance, maturity and risk assessment for LLM-based applications. *International Journal on Cybernetics and Informatics*.
- [4] European Parliament and Council of the European Union. (2016). *Regulation (EU) 2016/679 on the protection of natural persons with regard to the processing of personal data (GDPR)*. Official Journal of the European Union.
- [5] European Parliament and Council of the European Union. (2017). *Regulation (EU) 2017/745 on medical devices (Medical Device Regulation - MDR)*. Official Journal of the European Union.
- [6] European Parliament and Council of the European Union. (2024). *Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act)*. Official Journal of the European Union.
- [7] Guldimann, P., et al. (2024). COMPL-AI framework: A technical interpretation and LLM benchmarking suite for the EU Artificial Intelligence Act. *arXiv preprint arXiv:2410.07959*.
- [8] International Electrotechnical Commission (IEC). (2006). *IEC 62304:2006 - Medical device software — Software life cycle processes*.
- [9] International Organization for Standardization (ISO). (2019). *ISO 14971:2019 - Medical devices — Application of risk management to medical devices*.